
Clase 18: Aprendizaje Estadístico

Responsable: Francisco Velasco Medina

EST-25134, Primavera 2021

Dr. Alfredo Garbuno Iñigo

23 marzo 2021

1. Generalización de Máquinas de Soporte Vectorial

Definición 1.1. Definición

Un **espacio de Hilbert** es un espacio vectorial con producto interior y completo.

Llevamos los datos de $\psi(x) = (x, x^2)$ a $\text{signo}(\langle w, \psi(x) \rangle - b)$.

1. Consideramos un conjunto \mathcal{X} y una tarea de aprendizaje (clasificación). Usemos una función $\psi : \mathcal{X} \rightarrow \mathcal{F}$. $\mathcal{F} = \mathbb{R}^n$ puede ser un espacio de Hilbert.
2. Consideramos una muestra $S = \{(x_i, y_i)\}_{i=1}^m \rightarrow \hat{S} = \{(\psi(x_i), y_i)\}_{i=1}^m$.
3. Entrenamos con \hat{S} .
4. Predecimos con $(h \cdot \psi)(x) = h(\psi(x))$. ψ : enriquecer nuestra representación con los atributos.

2. El truco del kernel

Dada $\psi : \mathcal{X} \rightarrow \mathcal{F}$. Definimos el kernel como

$$\begin{aligned} k(x, x') &= \langle \psi(x), \psi(x') \rangle_{\mathcal{F}} \\ &= \langle x, x' \rangle_{\psi} \cdot \min_w L_S^H(w) + \lambda \|w\|_2^2 \\ &\Rightarrow \underbrace{\min_w (\langle w, \psi(x_1) \rangle, \langle w, \psi(x_2) \rangle + R(\|w\|_2))}_{(1) \text{ Monótona no decreciente}}, \end{aligned} \quad (1)$$

Teorema 2.1. Teorema del Representante

Si $\psi : \mathcal{X} \rightarrow \mathcal{F}$ donde \mathcal{F} es un espacio de Hilbert. Entonces $\exists \alpha \in \mathbb{R}^m$ tal que $w = \sum_{i=1}^m \alpha_i \psi(x_i)$ y además es una solución a (1).

Demostración. Sea w^* una solución a (1) y $w^* \in \mathcal{F}$

$$w^* = \sum_{i=1}^m \alpha_i \psi(x_i) + u$$

donde $\langle u, \psi(x_i) \rangle = 0, \forall i \in \{1, \dots, m\}$. Sea $w = w^* - u$:

$$\begin{aligned} &\Rightarrow \|w^*\|_2 = \|w\|_2 + \|u\|_2 \\ &\Rightarrow R(\|w\|_2) \leq R(\|w^*\|_2) \\ &\langle w, \psi(x_i) \rangle = \langle w^* - u, \psi(x_i) \rangle = \langle w^*, \psi(x_i) \rangle \quad \forall i \in \{1, \dots, m\} \\ &\Rightarrow f(w) = f(w^*) \end{aligned}$$

$\Rightarrow w$ es óptimo y además $w = \sum_{i=1}^m \alpha_i \psi(x_i)$

□

Entonces optimizamos (1) en términos de α .

$$\begin{aligned}
 \langle w, \psi(x_i) \rangle &= \sum_{j=1}^m \alpha_j \langle \psi(x_j), \psi(x_i) \rangle \\
 \|w\|_2^2 &= \langle w, w \rangle_{\mathcal{F}} \\
 &= \sum_{j,i}^m \alpha_j \alpha_i \langle \psi(x_j), \psi(x_i) \rangle \\
 &= \sum_{j,i}^m \alpha_j \alpha_i k(x_j, x_i) \\
 &= \alpha^T G \alpha
 \end{aligned}
 \quad \text{donde } G_{ij} = k(x_j, x_i)$$

$$\begin{aligned}
 \Rightarrow \min_{\alpha} f(\sum \alpha_j k(x_j, x_1), \dots, \sum \alpha_i k(x_j, x_m) + R(\sqrt{\alpha^T G \alpha})) \\
 \Rightarrow \min_{\alpha} \lambda \alpha^T G \alpha + \frac{1}{m} \sum_{i=1}^m \max\{0, 1 - y_i(G\alpha)_i\}
 \end{aligned}$$

Ejemplo 2.2. Ejemplos de kernel Polinomios de grado k: $k(x, x') = (1 + \langle x, x' \rangle)^k$; $\psi(x) = (1, x, \dots, x^k)$.

Kernel gaussiano: $k(x, x') = \exp(\frac{\|x - x'\|^2}{-2\sigma^2})$; $\psi(x) = (\dots, \frac{1}{\sqrt{n! \sigma^2}} \exp(\frac{-x^2}{2\sigma^2}) x^n, \dots$

Hiperbólico: $k(x, x') = \tanh(\sigma \langle x, x' \rangle + b)$

$$k(x, x') = \exp\left(\frac{\|x - x'\|_{\Sigma}^2}{-2}\right); \|r\|_{\Sigma}^2 = r^T \Sigma^{-1} r, \Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_k^2)$$

$$k(A, A') = 2^{|A \cap A'|}$$

Lema 2.3. El kernel $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ es válido para definir un producto interior en un espacio de Hilbert. \iff Es una función positiva definida. Es decir, $\forall x_1, \dots, x_m$ la matriz ψ es una matriz positiva definida.

2.1. Propiedades

Si k_1 y k_2 son dos kernel válidos

1. $k = k_1 + k_2$
2. $k = f(x)k_1(x, x')f(x')$
3. $k = \exp(k_1(x, x'))$
4. $k = k_1 \times k_2$
5. $k = k_1(x_a, x'_a) + k_2(x_b, x'_b), x = (x_a, x_b)$