

---

## Clase 05: Convergencia Uniforme

---

Responsable: Emanuel Santiago Payró Costilla

EST-25134, Primavera 2021

Dr. Alfredo Garbuno Iñigo

Enero 26, 2021

- Recordando lo visto anteriormente, dada una  $\mathcal{H}$  finita, en el ERM:
  1. Recibimos una muestra  $S \sim \mathcal{D}^m$ .
  2. Evaluamos el  $L_S$  en cada  $h \in \mathcal{H}$
  3.  $h_S \in \min_{h \in \mathcal{H}} L_S(h)$
- Esperamos que  $L_S(h_S)$  sea cercana a  $L_{\mathcal{D}}(h_S)$
- Necesitamos que todos los riesgos bajo  $\mathcal{H}$  sean buenas aproximaciones.

**Definition 0.1.**  $S$  es una muestra  $\varepsilon$ -representativa con respecto a  $Z$ ,  $\mathcal{D}$ ,  $l$  y  $\mathcal{H}$  si:

$$\forall h \in \mathcal{H}, \quad |L_S(h) - L_{\mathcal{D}}(h)| \leq \varepsilon$$

**Lemma 0.2.** Supongamos que  $S$  es un conjunto  $\frac{\varepsilon}{2}$ -representativo (c.r.a.  $Z$ ,  $\mathcal{D}$ ,  $l$  y  $\mathcal{H}$ ). Entonces  $h_S \in \min_{h \in \mathcal{H}} L_S(h)$  satisface:

$$L_{\mathcal{D}}(h_S) \leq \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h) + \varepsilon$$

**Definition 0.3.**  $\mathcal{H}$  tiene la propiedad de convergencia uniforme con respecto a  $Z$  y  $l$  si:

$\exists m_H^{uc} : (0, 1)^2 \rightarrow \mathbb{N}$  tal que  $\forall \varepsilon, \delta \in (0, 1)$  y toda distribución  $\mathcal{D}$  sobre  $Z$  tenemos que  $S$  es una muestra de tamaño  $m$ , donde  $m \geq m_H^{uc}(\varepsilon, \delta)$  entonces con probabilidad mayor o igual a  $1 - \delta$ ,  $S$  es  $\varepsilon$ -representativo.

**Corollary 0.4.** Si  $\mathcal{H}$  tiene convergencia uniforme con  $m_H^{uc}$ , entonces la clase puede aprender en el sentido PAC agnóstico, con una complejidad muestral:

$$m_{\mathcal{H}}(\varepsilon, \delta) \leq m_H^{uc}\left(\frac{\varepsilon}{2}, \delta\right)$$

Ahora nos gustaría establecer condiciones para definir cuando una clase de hipótesis es PAC aprendible de manera agnóstica. Para ello, vamos a:

1. Acotar la probabilidad de hacer un error generalizable por medio de uniones.
2. Utilizar un principio de concentración de medida para garantizar la desigualdad.

Para el primer inciso, dados  $\varepsilon, \delta$  necesitamos encontrar un tamaño de muestra  $m$  tal que  $\forall \mathcal{D}$  con probabilidad  $\geq 1 - \delta$ , la elección de la muestra  $S \sim \mathcal{D}^m$  garantiza que:

$$\forall h \in \mathcal{H} \quad |L_S(h) - L_{\mathcal{D}}(h)| \leq \varepsilon$$

Entonces si tenemos que:  $\mathcal{D}^m(\{S : \forall h \in \mathcal{H}, |L_S(h) - L_{\mathcal{D}}(h)| \leq \varepsilon\}) \geq 1 - \delta$

ó bien  $\mathcal{D}^m(\{S : \exists h \in \mathcal{H}, |L_S(h) - L_{\mathcal{D}}(h)| > \varepsilon\}) < \delta$

$$\begin{aligned} \text{Ahora como: } \{S : \exists h \in \mathcal{H}, |L_S(h) - L_{\mathcal{D}}(h)| > \varepsilon\} &= \bigcup_{h \in \mathcal{H}} \{S : |L_S(h) - L_{\mathcal{D}}(h)| > \varepsilon\} \\ \Rightarrow \mathcal{D}^m(\{S : \exists h \in \mathcal{H}, |L_S(h) - L_{\mathcal{D}}(h)| > \varepsilon\}) &\leq \sum_{h \in \mathcal{H}} \mathcal{D}^m(\{S : |L_S(h) - L_{\mathcal{D}}(h)| > \varepsilon\}) \end{aligned}$$

**Lemma 0.5. (*Desigualdad de Hoeffding*)** Si  $\theta_1, \dots, \theta_m$  son independientes e idénticamente distribuidas, tal que  $\forall i \quad \mathbb{E}(\theta_i) = \mu$  y  $\mathbb{P}(a \leq \theta \leq b) = 1$ , entonces:

$$\mathbb{P}(|\bar{\theta}_m - \mu| > \varepsilon) \leq 2 \exp\left(-\frac{2m\varepsilon^2}{(b-a)^2}\right) \text{ donde } \bar{\theta}_m = \frac{1}{m} \sum_{i=1}^m \theta_i$$

$$\theta_i = l(h, z_i); z_i \stackrel{iid}{\sim} \mathcal{D}; \theta_i \text{ iid.}$$

$$\bar{\theta}_m = L_S(\theta) \quad \mu = L_{\mathcal{D}}(h)$$

$$l(h, \cdot) \in [0, 1] \quad \Rightarrow \quad \theta_i \in [0, 1]$$

$$\mathcal{D}^m(\{S : |L_S(h) - L_{\mathcal{D}}(h)| > \varepsilon\}) = \mathbb{P}(|\bar{\theta}_m - \mu| > \varepsilon) \leq 2 \exp(-2m\varepsilon^2)$$

$$\Rightarrow \mathcal{D}^m(\{S : \exists h \in \mathcal{H}, |L_S(h) - L_{\mathcal{D}}(h)| > \varepsilon\}) \leq \sum_{h \in \mathcal{H}} 2 \exp(-2m\varepsilon^2)$$

$$= 2|\mathcal{H}| \exp(-2m\varepsilon^2)$$

$$\Rightarrow m \geq \frac{\log(\frac{2|\mathcal{H}|}{\delta})}{2\varepsilon^2}$$

**Corollary 0.6.** Sea  $\mathcal{H}$  una clase finita de hipótesis,  $\mathcal{Z}$  el dominio y  $l: \mathcal{H} \times \mathcal{Z} \rightarrow [0, 1]$  una función de pérdida. Entonces  $\mathcal{H}$  posee la propiedad de convergencia uniforme con complejidad muestral:

$$m_{\mathcal{H}}^{uc}(\varepsilon, \delta) \leq \left\lceil \frac{\log(\frac{2|\mathcal{H}|}{\delta})}{2\varepsilon^2} \right\rceil$$

Además, el algoritmo ERM utilizando una complejidad muestral:

$$m_{\mathcal{H}}(\varepsilon, \delta) \leq m_{\mathcal{H}}^{uc}(\frac{\varepsilon}{2}, \delta)$$

Nos garantiza que  $\mathcal{H}$  es aprendible como PAC agnóstico.

**Resumen:** Si tenemos convergencia uniforme para  $\mathcal{H}$  entonces  $L_S$  estará cercano a  $L_{\mathcal{D}}$

Si CU + ERM  $\Rightarrow$  PAC agnóstico

## **Agradecimientos**

Este *template* se ha adaptado y traducido del provisto en la clase ACM 204 (Otoño 2017) por el profesor Joel Tropp.

## **Referencias**